



UNIVERSIDADE CATÓLICA DE BRASÍLIA - UCB
ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

BIANCA MELLINY DE LIMA VAZ
GUILHERME FERNANDES REZENDE
ISABELA MARTINS BANDEIRA
JOÃO FILIPE ALVES DE ALBUQUERQUE SILVA
NATÁLIA EMATNÉ KRUCHAK

**COMPARAÇÃO DE ALGORITMOS DE CLASSIFICAÇÃO SUPERVISIONADA EM
R E PYTHON: UM ESTUDO APLICADO À QUALIDADE DE CERVEJAS**

Brasília - DF
2026

SUMÁRIO

1. INTRODUÇÃO	3
2. FUNDAMENTAÇÃO TEÓRICA	3
2.1. Classificação supervisionada	3
2.2. Naive Bayes	4
2.3. Árvore de Decisão	4
2.4. Random Forest	5
2.5. Métricas de avaliação	5
3. METODOLOGIA	5
3.1. Base de dados	5
3.2. Pré-processamento	6
3.3. Divisão dos dados	6
3.4. Padronização entre R e Python	6
4. IMPLEMENTAÇÃO	7
5. RESULTADOS	7
5.1. Tabela comparativa dos modelos	8
5.2. Análise dos resultados	8
5.3. Gráfico comparativo das métricas	8
5.4. Matrizes de confusão	9
5.5. Análise geral dos resultados	12
6. DISCUSSÃO	12
7. CONCLUSÃO	13
8. REFERÊNCIAS BIBLIOGRÁFICAS	14
APÊNDICE A – TABELA COMPARATIVA FINAL DOS MODELOS	15

1. INTRODUÇÃO

O avanço das técnicas de Ciência de Dados e Aprendizado de Máquina tem possibilitado a extração de conhecimento a partir de grandes volumes de dados, contribuindo significativamente para a tomada de decisões em diversos contextos.

Nesse cenário, a classificação supervisionada destaca-se como uma abordagem amplamente utilizada para prever categorias a partir de dados previamente rotulados, sendo aplicada em áreas como análise de crédito, diagnóstico médico e sistemas de recomendação (MITCHELL, 1997).

O presente trabalho tem como objetivo aplicar e comparar três algoritmos clássicos de classificação — Naive Bayes, Árvore de Decisão e Random Forest — utilizando as linguagens R e Python, com base em um problema real de classificação.

O problema escolhido consiste em classificar a qualidade de cervejas com base em avaliações reais, categorizando-as como “Comum” ou “Excelente”, a partir de atributos sensoriais e características físico-químicas.

Além da análise de desempenho dos modelos, este estudo busca avaliar aspectos como interpretabilidade, robustez e diferenças entre as implementações nas duas linguagens.

2. FUNDAMENTAÇÃO TEÓRICA

2.1. Classificação supervisionada

A classificação supervisionada consiste no treinamento de modelos a partir de dados rotulados, permitindo que o algoritmo aprenda padrões e realize previsões sobre novos dados (MITCHELL, 1997).

Segundo Mitchell (1997), um programa aprende a partir da experiência quando seu desempenho em uma tarefa melhora com base nos dados utilizados no treinamento.


2.2. Naive Bayes

O algoritmo Naive Bayes é um classificador probabilístico baseado no Teorema de Bayes, assumindo independência condicional entre as variáveis explicativas.

De acordo com Bishop (2006), esse modelo é eficiente do ponto de vista computacional e apresenta bom desempenho mesmo em bases de dados com alta dimensionalidade.

Apesar da hipótese de independência ser simplificadora, o Naive Bayes frequentemente apresenta resultados competitivos em diversas aplicações práticas (BISHOP, 2006).

Figura 1: Naive Bayes



Fonte: Medium, 2024

2.3. Árvore de Decisão

A Árvore de Decisão é um modelo que realiza classificações por meio de divisões sucessivas dos dados, organizadas em uma estrutura hierárquica.

Segundo Quinlan (1993), esse tipo de algoritmo é capaz de representar conhecimento de forma clara e interpretável, facilitando a compreensão das decisões tomadas pelo modelo.

Além disso, árvores de decisão são eficazes na modelagem de relações não lineares entre variáveis, sendo amplamente utilizadas em problemas de classificação (QUINLAN, 1993).

2.4. Random Forest

O Random Forest é um algoritmo de aprendizado de máquina baseado na combinação de múltiplas árvores de decisão, utilizando técnicas de amostragem aleatória e agregação.

De acordo com Breiman (2001), esse método reduz a variância dos modelos individuais, aumentando a robustez e a capacidade de generalização.

Estudos indicam que o Random Forest tende a apresentar melhor desempenho em comparação com modelos individuais, especialmente em problemas com grande volume de dados (BREIMAN, 2001).

2.5. Métricas de avaliação

A avaliação de modelos de classificação deve considerar diferentes métricas, como acurácia, precisão, recall e F1-score.

Segundo Pedregosa et al. (2011), a análise dessas métricas permite uma compreensão mais completa do desempenho dos modelos, especialmente em cenários com possíveis desbalanceamentos entre classes.

A matriz de confusão também desempenha papel fundamental, pois detalha os acertos e erros do modelo.

3. METODOLOGIA

3.1. Base de dados

Foi utilizada a base Beer Reviews Dataset, disponível na plataforma Kaggle (KAGGLE, 2026), contendo avaliações reais de cervejas.

Devido ao grande volume de dados, foi aplicada uma amostragem aleatória de 1% da base original, garantindo maior eficiência computacional sem comprometer a análise.

Essa amostragem foi realizada utilizando a mesma semente aleatória ($\text{seed} = 42$) tanto em R quanto em Python, assegurando consistência entre as implementações.

3.2. Pré-processamento

As etapas de pré-processamento incluíram:

- remoção de atributos irrelevantes
- seleção das variáveis mais relevantes (`beer_abv`, `review_aroma`, `review_palate`)
- tratamento de valores ausentes utilizando a mediana
- criação da variável alvo categórica (qualidade)

A variável alvo foi definida como:

- 1 (Excelente): $\text{nota} \geq 4.0$
- 0 (Comum): $\text{nota} < 4.0$

3.3. Divisão dos dados

Os dados foram divididos em:

- 80% para treino
- 20% para teste

A divisão foi realizada utilizando técnicas de amostragem estratificada, preservando a proporção entre as classes.

A utilização da mesma semente aleatória ($\text{seed} = 42$) garantiu a reprodutibilidade dos experimentos.

3.4. Padronização entre R e Python

Para garantir uma comparação justa entre as linguagens, foram adotadas as seguintes estratégias:

- utilização da mesma base de dados (amostrada)
- aplicação do mesmo pré-processamento

- definição da mesma variável alvo
- uso da mesma proporção de treino e teste (80/20)
- utilização da mesma semente aleatória (42)

Essa padronização permite que as diferenças observadas nos resultados estejam relacionadas aos algoritmos e às linguagens, e não a variações nos dados.

4. IMPLEMENTAÇÃO

A implementação dos modelos foi realizada nas linguagens Python e R, com o objetivo de comparar não apenas o desempenho dos algoritmos, mas também as particularidades de cada ambiente.

Em Python, foi utilizado o ambiente Google Colab, com apoio das bibliotecas pandas, numpy, scikit-learn, matplotlib e seaborn, que possibilitam desde a manipulação de dados até a visualização e avaliação dos modelos.

Já em R, foram utilizadas as bibliotecas caret, e1071, rpart, randomForest e dplyr, amplamente empregadas em análise estatística e aprendizado de máquina.

Em ambas as linguagens, foram implementados os três algoritmos propostos — Naive Bayes, Árvore de Decisão e Random Forest — seguindo a mesma lógica de treinamento e avaliação.

Além disso, foram utilizadas funções padronizadas para cálculo de métricas, garantindo consistência na análise comparativa entre os modelos.

5. RESULTADOS

Nesta seção, são apresentados os resultados obtidos a partir da aplicação dos algoritmos de classificação supervisionada nas linguagens R e Python.

A avaliação dos modelos foi realizada com base nas métricas de **acurácia**, **precisão**, **recall** e **F1-score**, além da análise por meio da **matriz de confusão**.

5.1. Tabela comparativa dos modelos

A Tabela 1 apresenta os resultados obtidos para os seis modelos avaliados.

Tabela 1: Comparação dos modelos de classificação em R e Python

Algoritmo	Linguagem	Acurácia	Precisão	Recall	F1-score
Naive Bayes	Python	0.7820	0.7848	0.8997	0.8383
Árvore de Decisão	Python	0.7836	0.8107	0.8551	0.8323
Random Forest	Python	0.7735	0.8003	0.8521	0.8254
Naive Bayes	R	0.7926	0.7913	0.9109	0.8469
Árvore de Decisão	R	0.7973	0.8132	0.8803	0.8454
Random Forest	R	0.7992	0.8111	0.8878	0.8477

Fonte: Elaborado pelos autores.

5.2. Análise dos resultados

Observa-se que os modelos apresentaram desempenhos semelhantes entre si, com pequenas variações nas métricas avaliadas.

O algoritmo Random Forest, na linguagem R, apresentou o melhor desempenho geral, com maior valor de F1-score (0.8477) e acurácia (0.7992).

De forma geral, os modelos implementados em R apresentaram resultados ligeiramente superiores aos obtidos em Python, indicando consistência entre as implementações, porém com pequenas diferenças decorrentes das bibliotecas utilizadas.


5.3. Gráfico comparativo das métricas

Para facilitar a análise dos resultados, foi elaborado um gráfico comparativo das métricas avaliadas.

O gráfico permite visualizar o desempenho dos modelos de forma mais intuitiva, evidenciando as diferenças entre os algoritmos e as linguagens utilizadas.

Observa-se que os modelos apresentam desempenhos semelhantes, com leve destaque para os modelos implementados em R.

Figura 2: Gráfico comparativo



Fonte: Elaborado pelos autores.


5.4. Matrizes de confusão

As matrizes de confusão apresentadas referem-se a todos os modelos avaliados, permitindo análise individual do desempenho de cada algoritmo.


Por meio dessas matrizes, é possível identificar:

- Verdadeiros Positivos (VP)
- Verdadeiros Negativos (VN)
- Falsos Positivos (FP)
- Falsos Negativos (FN)


Essa análise permite compreender o comportamento dos modelos além da acurácia.

Figura 3: Matriz de Confusão - Naive Bayes (Python)

Fonte: Elaborado pelos autores.

Figura 4: Matriz de confusão – Árvore de Decisão (Python)

Fonte: Elaborado pelos autores.

Figura 5: Matriz de confusão – Random Forest (Python)

Fonte: Elaborado pelos autores.

Figura 6: Matriz de confusão – Naive Bayes (R)

Reference		
Prediction	0	1
0	695	178
1	480	1820

Fonte: Elaborado pelos autores.

Figura 7: Matriz de confusão – Árvore de Decisão (R)

Reference		
Prediction	0	1
0	771	239
1	404	1759

Fonte: Elaborado pelos autores.

Figura 8: Matriz de confusão – Random Forest (R)

	Reference	
Prediction	0	1
0	762	224
1	413	1774

Fonte: Elaborado pelos autores.

5.5. Análise geral dos resultados

De forma geral, observa-se que os modelos apresentaram desempenhos próximos, indicando que todos foram capazes de capturar padrões relevantes nos dados.

O modelo Random Forest implementado em R apresentou o melhor desempenho geral, com maior valor de F1-score (0.8477), indicando melhor equilíbrio entre precisão e recall.

Os modelos implementados em Python apresentaram resultados consistentes, porém ligeiramente inferiores aos obtidos em R.

6. DISCUSSÃO

O Naive Bayes apresentou desempenho competitivo, especialmente considerando sua simplicidade e baixo custo computacional. Apesar da suposição de independência entre as variáveis, o modelo demonstrou boa capacidade de generalização (BISHOP, 2006).

A Árvore de Decisão apresentou desempenho intermediário, com a vantagem de ser altamente interpretável. Esse tipo de modelo permite compreender claramente as regras de decisão, sendo útil em cenários que exigem transparência (QUINLAN, 1993).

O Random Forest, por sua vez, apresentou o melhor desempenho geral, corroborando os achados da literatura (BREIMAN, 2001). Sua capacidade de combinar múltiplas árvores reduz a variância e aumenta a robustez, tornando-o mais eficaz em problemas complexos.

Outro ponto relevante é a comparação entre as linguagens R e Python. Observou-se que os modelos implementados em R apresentaram desempenho ligeiramente superior em relação aos implementados em Python.

Essa diferença pode estar associada a variações nos algoritmos internos, parâmetros padrão e formas de implementação das bibliotecas utilizadas em cada linguagem.

Entretanto, como os experimentos foram devidamente padronizados — incluindo a utilização da mesma base de dados, mesma amostragem e mesma divisão entre treino e teste — é possível afirmar que ambas as linguagens apresentaram resultados consistentes e comparáveis.

7. CONCLUSÃO

Com base nos resultados obtidos, conclui-se que os resultados obtidos demonstraram que todos os modelos foram capazes de capturar padrões relevantes nos dados, apresentando desempenhos próximos entre si. No entanto, observou-se que o algoritmo Random Forest, especialmente na implementação em R, apresentou o melhor desempenho geral, com maior valor de F1-score, indicando melhor equilíbrio entre precisão e recall.

O algoritmo Naive Bayes mostrou-se eficiente como modelo simples e de baixo custo computacional, enquanto a Árvore de Decisão destacou-se pela interpretabilidade, permitindo compreender de forma clara as regras de classificação.

A comparação entre as linguagens evidenciou que tanto R quanto Python são ferramentas adequadas para a aplicação de técnicas de aprendizado de máquina, apresentando resultados consistentes. Entretanto, os modelos implementados em R apresentaram desempenho ligeiramente superior, possivelmente devido a diferenças nas bibliotecas e parâmetros utilizados.

Como limitação do estudo, destaca-se a utilização de uma amostra reduzida da base de dados, o que pode influenciar a generalização dos resultados. Trabalhos

futuros podem explorar o uso da base completa, além da aplicação de técnicas de ajuste de hiperparâmetros e a avaliação de outros algoritmos de classificação.

Dessa forma, conclui-se que o Random Forest é o modelo mais adequado para o problema analisado, e que a escolha entre R e Python pode depender do contexto de aplicação, das ferramentas disponíveis e da preferência do usuário.

8. REFERÊNCIAS BIBLIOGRÁFICAS

BISHOP, Christopher M. **Pattern Recognition and Machine Learning**. New York: Springer, 2006

BREIMAN, Leo. Random forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001.

KAGGLE. Beer Reviews Dataset. Disponível em: <https://www.kaggle.com/datasets/rdoume/beerreviews>. Acesso em: 2026

MITCHELL, Tom M. **Machine Learning**. New York: McGraw-Hill, 1997.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825–2830, 2011

QUINLAN, J. Ross. **C4.5: Programs for Machine Learning**. San Mateo: Morgan Kaufmann, 1993

APÊNDICE A – TABELA COMPARATIVA FINAL DOS MODELOS

Algoritmo	Linguagem	Acurácia	Precisão	Recall	F1-score
Naive Bayes	Python	0.7820	0.7848	0.8997	0.8383
Árvore de Decisão	Python	0.7836	0.8107	0.8551	0.8323
Random Forest	Python	0.7735	0.8003	0.8521	0.8254
Naive Bayes	R	0.7926	0.7913	0.9109	0.8469
Árvore de Decisão	R	0.7973	0.8132	0.8803	0.8454
Random Forest	R	0.7992	0.8111	0.8878	0.8477